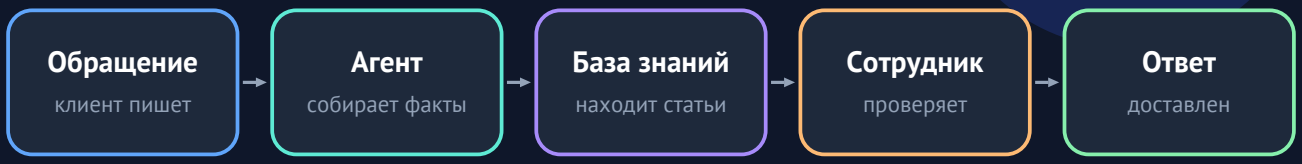
УЧЕБНЫЙ ПРОЕКТ · ВЫМЫШЛЕННАЯ КОМПАНИЯ TECHFLOW

AI Support Agent

Наглядный гайд по проекту: как ИИ-помощник готовит ответ оператору поддержки - от обращения клиента до одобренного человеком ответа.



Решение всегда за человеком: агент только готовит черновик.

10 / 10	1306	28 / 35	5	5
этапов дорожной карты готово	автоматических тестов	пути / операции HTTP API	инструментов агента	миграции базы данных

Что внутри

1 Проект за минуту
2 Архитектура
3 Путь обращения
4 Как работает агент
5 База знаний (RAG)
6 LangGraph и решение человека
7 Данные и миграции
8 Шпаргалка API
9 Как запустить
10 Проверки и CI/CD
11 Интерфейс оператора
12 Оценки и демонстрация
13 Дорожная карта
14 Словарь
15 Итоги аудита
16 Матрица CI
17 Защита и доставка
18 Полный прогон
19 Путь оператора
20 Перезапуск и копии
21 Диагностика
22 Покрытие и recovery
23 Обновления и релизы
24 Следующие шаги

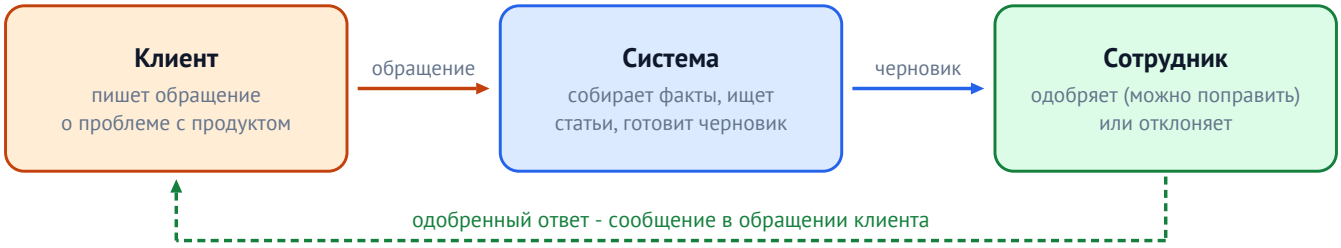
Аудит 2026-10-19 · основа 4962feb · mock без платных запросов

Подробные пошаговые инструкции - в docs/STAGE_01-10.md, docs/DEMO.md и docs/instructions/

1 Проект за одну минуту

Зачем нужен помощник оператора и что он делает - без технических деталей.

Оператор технической поддержки тратит много времени на сбор фактов: кто клиент, действует ли его лицензия, обращался ли он раньше, что сказано в документации. **AI Support Agent** собирает эти факты автоматически и готовит черновик ответа со ссылками на статьи базы знаний. **Отправлять ли ответ, решает человек.**



Что делает

Читает обращение, клиента, лицензию и историю; ищет статьи; готовит черновик со ссылками; ждёт решения сотрудника; доставляет одобренный ответ сообщением в обращении.

Чего не делает

Не отправляет письма; не меняет обращение без человека; не вызывает платную модель по умолчанию (режим mock); не принимает запросы /api/* без токена сотрудника.

Главные принципы

Человек в контуре; агент только читает данные; безопасные ошибки без секретов; каждое изменение проверяют тесты и CI перед публикацией образа.

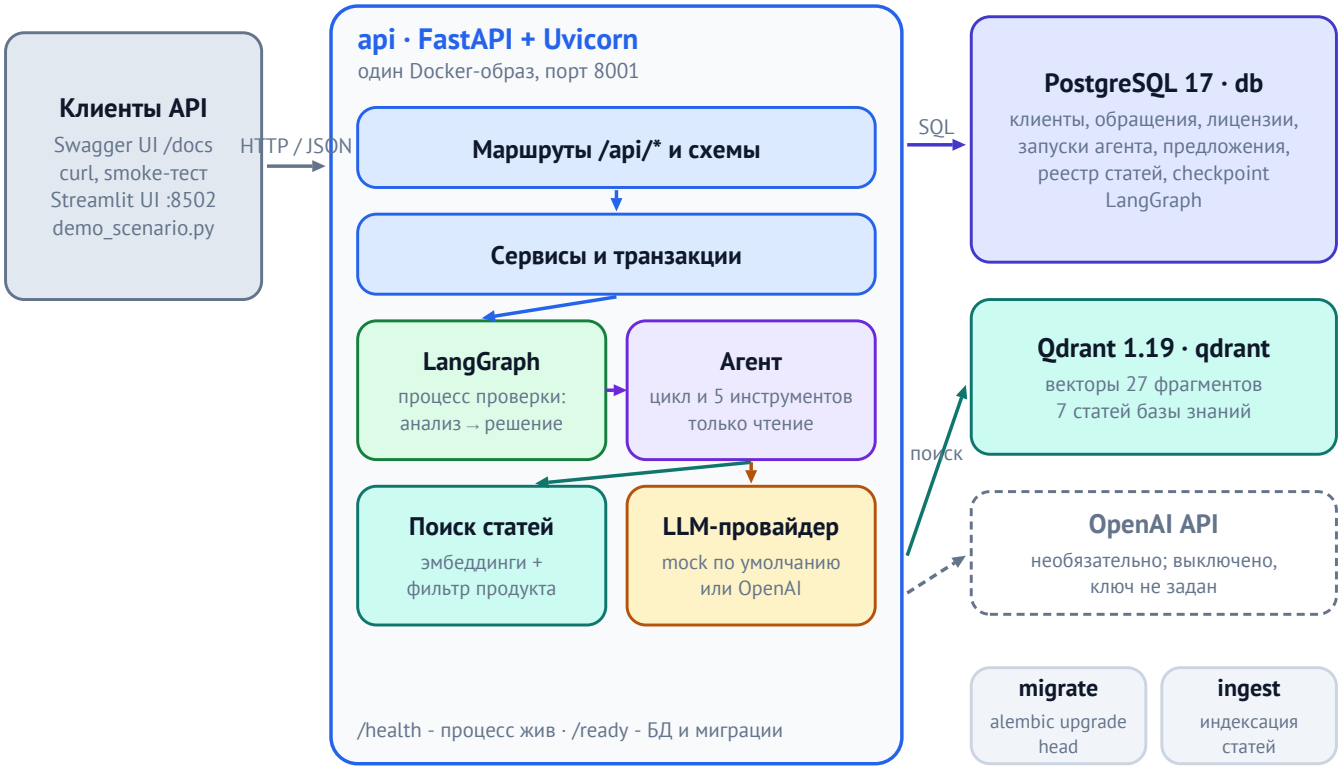
Как устроен проект

Слой	Технология	Зачем
HTTP API	FastAPI + Uvicorn	Маршруты, проверка JSON, документация Swagger
Данные	PostgreSQL 17, SQLAlchemy 2, Alembic	Записи, транзакции, версии схемы
Агент	Свой цикл tool calling	5 инструментов только для чтения, лимиты, проверка итога
Поиск	Qdrant 1.19 + эмбеддинги	Статьи базы знаний по смыслу (mock - по словам)
Процесс	LangGraph + PostgresSaver	Ожидание решения человека, переживает перезапуск
Доставка	Docker Compose, GitHub Actions, GHCR	Запуск одной командой и проверенный образ

Важно: TechFlow, клиенты и статьи - вымышленные. Режим **mock** по умолчанию работает без интернета и ключей: он показывает путь данных, но не качество настоящей модели. Подключение OpenAI подготовлено, но в проекте ещё не включалось.

2 Архитектура

Из каких частей состоит система и как они связаны.



Сервисы Docker Compose

Сервис	Что это	Порт на Mac	Данные
`db`	PostgreSQL 17	5433	том postgres_data
`qdrant`	Qdrant 1.19.1, телеметрия выключена	6335	том qdrant_data
`migrate`	разовый: alembic upgrade head	-	-
`api`	FastAPI; стартует после migrate и qdrant	8001	-
`ui`	Streamlit; стартует после healthy api	8502	-
`db-test`	тестовая PostgreSQL (профиль test)	5434	в памяти
`qdrant-test`	тестовый Qdrant (профиль test)	6336	в памяти

Порядок запуска: **db healthy** → **migrate завершился** → **qdrant healthy** → **api healthy** → **ui healthy**. Обычный `docker compose down` сохраняет тома: записи, индекс статей и ожидающие решения переживают пересоздание контейнеров. `down --volumes` удаляет всё.

3 Путь обращения: от создания до ответа

Восемь шагов, через которые проходит каждое обращение. Справа - где это видно в API.

1. **Создать данные**
   Клиент, продукт, лицензия и обращение (статус open).
   `POST /api/tickets`

2. **Запустить анализ**
   Стартует граф LangGraph; первый узел - агент.
   `POST /api/tickets/{id}/analyze`

3. **Агент читает факты**
   Обращение, клиент без email, история, лицензия по ключу оператора - только чтение.
   `get_ticket · get_license`

4. **Агент ищет статьи**
   Статьи продукта обращения и общие статьи в Qdrant.
   `search_knowledge`

5. **Черновик со ссылками**
   summary, category, draft_reply, sources. Запуск completed, предложение pending.
   `GET /api/agent-runs/{id}`

6. **Граф ждёт человека**
   interrupt(): состояние сохранено в PostgreSQL, ждать можно сколько угодно.
   `GET …/workflow → awaiting_review`

7. **Сотрудник решает**
   approve - можно отредактировать текст; reject - с причиной.
   `POST /api/suggestions/{id}/review`

8. **Ответ доставлен**
   Сообщение оператора в обращении, статус waiting_customer, граф delivered.
   `ticket_messages`

Очередь на проверку: `GET /api/suggestions?status=pending`. Каждый повторный анализ создаёт новый запуск и новое предложение; решение по предложению принимается один раз.

4 Как работает агент

Модель просит факты, сервер решает, что можно выполнить, и проверяет итог.



Инструмент	Что возвращает	Ограничение
`get_ticket`	Текущее обращение и продукт	только обращение этого запуска
`get_customer`	Имя и компания клиента	email не выдаётся
`get_license`	Статус и признак valid по датам	только клиент и продукт обращения; ключ в журнале - ***
`get_ticket_history`	До 5 других обращений	тот же клиент и продукт, без описаний
`search_knowledge`	До 5 статей, по фрагменту от каждой	продукт задаёт сервер: свои статьи + общие

⩽ 6	⩽ 12	⩽ 60 с	64 000
шагов модели за запуск	вызовов инструментов	на весь цикл	символов истории максимум

Безопасность: имя функции и JSON модели никогда не превращаются в код или SQL. Транзакции инструментов - **READ ONLY** на уровне PostgreSQL. Ссылка в `sources` на статью, которую поиск не находил, останавливает запуск с ошибкой 502. Ошибка после старта сохраняется как **failed** с `run_id`, без предложения.

5 База знаний и поиск (RAG)

RAG - ответ с опорой на найденные документы. Сначала поиск, потом черновик со ссылками.



Повторный запуск: без изменений → unchanged;
изменённая статья → переиндексирована;
удалённая из каталога → убрана отовсюду.

Как работает поиск

Текст запроса превращается в вектор той же моделью, что и статьи. Qdrant сравнивает его с векторами фрагментов (косинусное сходство: 1 - одинаковое направление векторов, около 0 - слабая связь векторов) и отбрасывает всё ниже порога. С кодом продукта ищутся статьи этого продукта и общие; агенту продукт подставляет сервер.

Запрос: «Где найти журнал сервера и собрать диагностику»



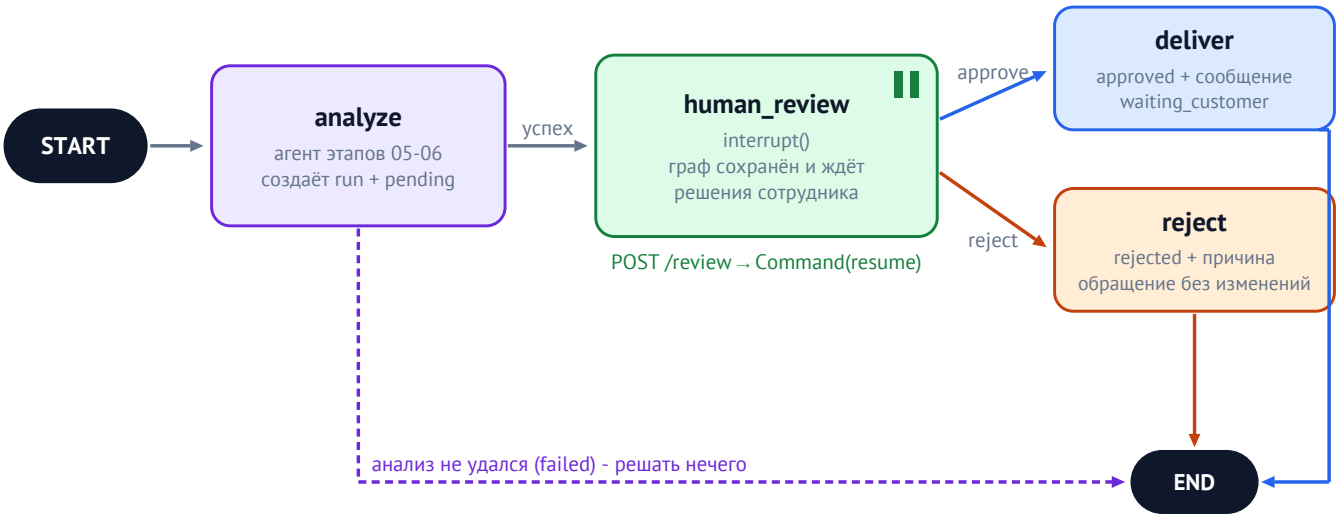
Серые столбцы ниже порога в выдачу не попадают. Данные - настоящий поиск mock-эмбеддингов по 27 фрагментам без фильтра продукта.

Mock-эмбеддинг - лексический: слова приводятся к основе из 5 букв («ошибка», «ошибке» → «ошибк»), каждая основа через SHA-256 попадает в одну из 256 координат. Он находит тексты с общими словами, но не понимает синонимы. Адаптер OpenAI-эмбеддингов готов; после смены модели статьи нужно переиндексировать.

6 LangGraph и решение человека

Процесс как граф: после анализа он останавливается и ждёт сотрудника.

После каждого узла LangGraph сохраняет состояние потока (checkpoint) в PostgreSQL.



Решение	Что передать	Что произойдёт
approve	токен reviewer/admin; можно final_content - новый текст	Предложение approved, сообщение оператора в обращении, статус waiting_customer, граф delivered
reject	токен reviewer/admin и обязательный comment с причиной	Предложение rejected, обращение без изменений, граф rejected

Проверка до продолжения

Без токена - 401, роль operator - 403, одобрение закрытого обращения - 409, а граф продолжает ждать.

Одно решение

Advisory lock и SELECT ... FOR UPDATE: из двух одновременных решений применяется одно, второе получает 409.

Перезапуск не страшен

Состояние в PostgreSQL. CI пересоздаёт контейнеры и продолжает отложенный граф.

Без лишних данных

В checkpoint только id и итоги; ключ лицензии туда не попадает.

Неудачный анализ

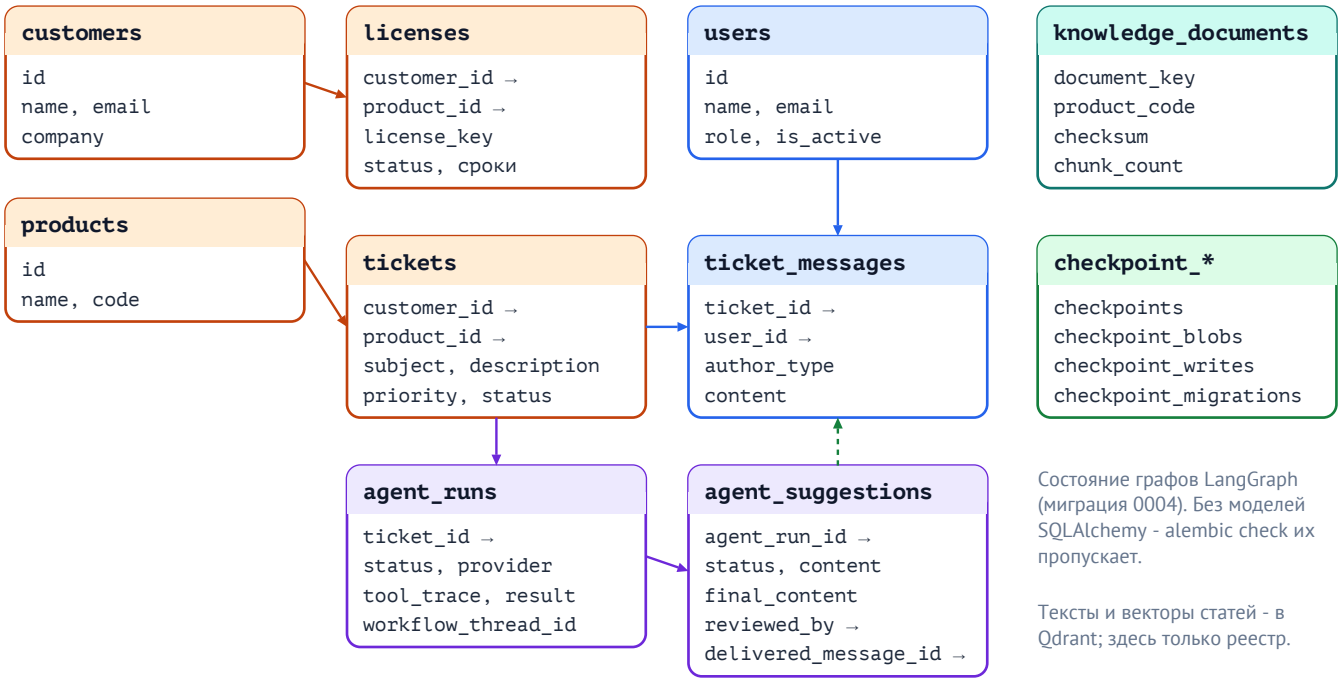
Запуск failed завершает граф: состояние failed, предложения нет.

Автор из токена

Автора решения API берёт из токена сотрудника; поле reviewer_id в теле запрещено (422).

7 Данные: таблицы и миграции

Что хранится в PostgreSQL и как схема менялась от этапа к этапу.

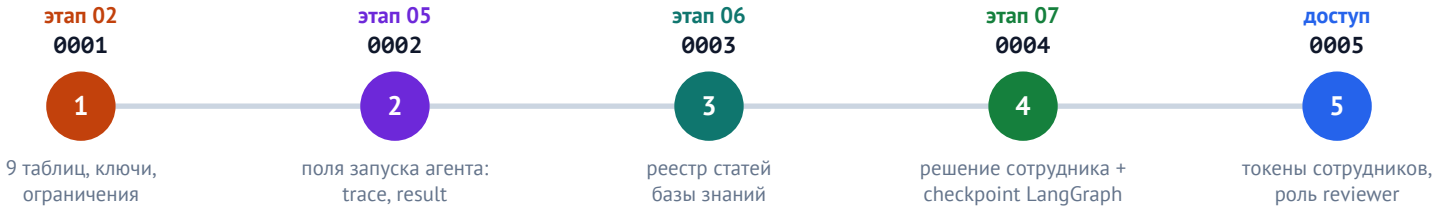


Состояние графов LangGraph (миграция 0004). Без моделей SQLAlchemy - alembic check их пропускает.

Тексты и векторы статей - в Qdrant; здесь только реестр.

Стрелки - внешние ключи; пунктир - сообщение, созданное доставкой одобренного ответа. Таблица api_tokens (миграция 0005) хранит только SHA-256 токенов и ссылается на users.

Миграции Alembic



Схему меняет **только Alembic**: сервис migrate применяет миграции до старта API, а `/ready` отвечает 200, лишь когда версия БД совпадает с кодом. Старая миграция не переписывается - каждое изменение получает новую версию. Проверки отката выполняются только на одноразовой тестовой БД.

8 Шпаргалка API

28 путей, 35 операций; /api/* - только с токеном. Документация - /docs.

Раздел	Метод	Путь	Что делает
Состояние	`GET`	`/health · /ready`	API жив · БД и миграции готовы
Ресурсы	`POST / GET`	`/api/customers`	Создать или список клиентов
	`POST / GET`	`/api/products`	Продукты
	`POST / GET`	`/api/licenses`	Лицензии (фильтры клиента, продукта, ключа)
	`POST / GET`	`/api/tickets`	Обращения (новые всегда open)
	`POST / GET`	`/api/users`	Сотрудники и их роли (создаёт admin)
	`GET`	`/api/{ресурс}/{id}`	Одна запись любого ресурса выше
LLM	`GET`	`/api/llm/status`	Какой провайдер настроен
	`POST`	`/api/tickets/{id}/draft`	Предварительный черновик без сохранения
База знаний	`GET`	`/api/knowledge/status`	Индекс, точки, статьи реестра
	`POST`	`/api/knowledge/search`	Поиск фрагментов, фильтр product_code
Агент	`POST`	`/api/tickets/{id}/analyze`	Анализ и граф проверки; 409 - закрыто или ждёт решения
	`GET`	`/api/agent-runs[/{id}]`	История (фильтр ticket_id) или один запуск
Проверка	`GET`	`/api/agent-runs/{id}/workflow`	Состояние графа LangGraph
	`GET`	`/api/suggestions[/{id}]`	Очередь (status, ticket_id) или одно
	`POST`	`/api/suggestions/{id}/review`	Одобрить или отклонить
Оператор	`GET`	`/api/dashboard`	Агрегаты всей БД для обзора
	`GET`	`/api/tickets/{id}/messages`	Сообщения обращения
	`PATCH`	`/api/tickets/{id}`	Только смена статуса обращения
Доступ	`GET`	`/api/auth/me`	Сотрудник, роль и срок своего токена
	`POST / GET`	`/api/users/{id}/tokens`	Выдать токен или список (admin)
	`DELETE`	`/api/tokens/{id}`	Отозвать токен (admin)

Коды ответов

Код	Значение	Код	Значение
200 / 201	успех / запись создана	**401 / 403**	нет действующего токена / роль ниже нужной
404	запись не найдена	**413 / 429**	контекст велик / лимит изменений в минуту
409	дубликат, решение принято, обращение закрыто	**502**	непригодный ответ модели или чужая ссылка
422	неверный запрос: поля, типы, лишнее	**503 / 504**	БД, Qdrant, провайдер недоступны / тайм-аут

9 Как запустить у себя

Python 3.12+, uv 0.12.23 и Docker. Linux, macOS и Windows - команды из корня проекта.

1 Настройки и зависимости

```
cp -n .env.example .env
uv sync --locked
```

cp -n не перезапишет существующий .env.

2 Запустить стенд

```
docker compose up --build --detach --wait --wait-timeout 180 ui
```

Поднимет db и qdrant, применит миграции, запустит API и UI на :8502.

3 Проиндексировать статьи

```
docker compose exec -T api python -m app.knowledge.ingest
```

Повторный запуск ничего не перепишет.

4 Выдать токен администратора

```
export API_TOKEN="$(docker compose exec -T api python -m \
  app.tokens issue --email admin@example.com --name Admin --role admin)"
```

Показывается один раз; им же входят в UI и Swagger (Authorize).

5 Проверить всё одной командой

```
uv run --locked python scripts/smoke_test.py \
  --base-url http://127.0.0.1:8001 --timeout 60 --check-review
```

Токен берёт из API_TOKEN; создаёт учебные записи - не на рабочей базе.

Адрес	Что там
`http://127.0.0.1:8001/docs`	Swagger UI - все операции
`http://127.0.0.1:8502`	Интерфейс оператора Streamlit
`http://127.0.0.1:8001/ready`	{"status":"ok","database":"ok"} - БД и миграции готовы
`127.0.0.1:5433 / 127.0.0.1:6335`	PostgreSQL / Qdrant для инструментов на Mac

Windows: PowerShell 7, Git Bash или WSL 2; аналоги команд - `docs/instructions/windows.md`. Проверить запуск без Docker на любой ОС: `uv run --locked python scripts/check_local_start.py`.

Остановить: `docker compose down` - данные сохранятся. Чтобы подключить OpenAI, задай в .env `LLM_PROVIDER=openai`, ключ и модель; это платно и отправляет данные провайдеру.

10 Проверки качества и CI/CD

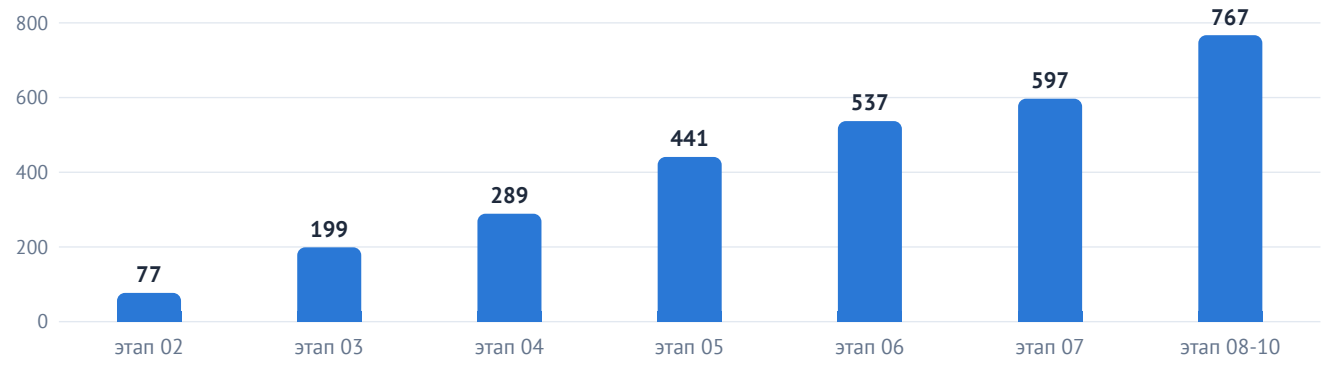
Каждое изменение проверяется автоматически, прежде чем API и UI попадут в реестр.

1143
unit-тестов: без сети, БД - заглушки и Qdrant в памяти

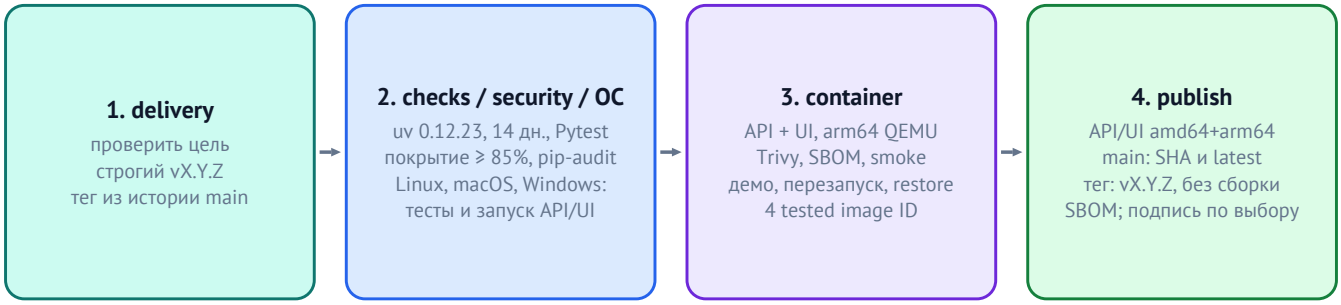
163
интеграционных: настоящие PostgreSQL и Qdrant

112
включены в unit: тесты smoke CLI; сам smoke - на живом стенде

Сколько тестов было после каждого этапа



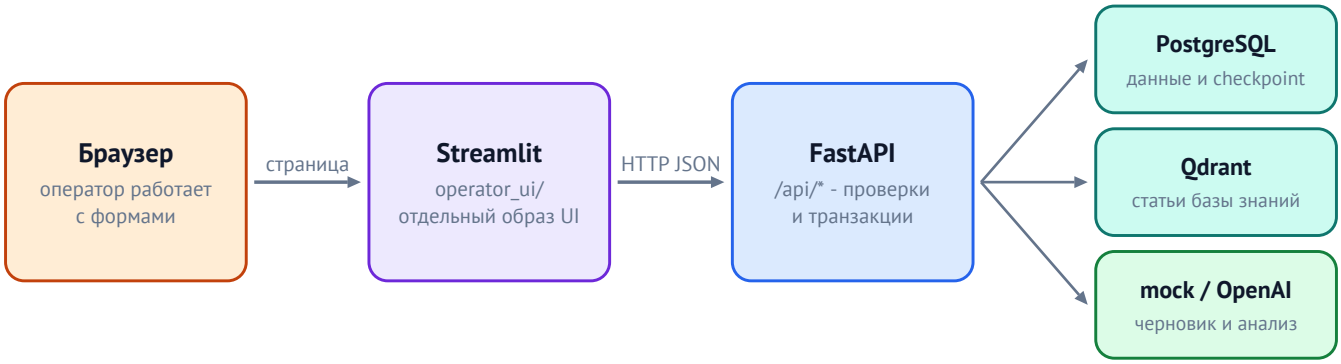
Конвейер GitHub Actions



Тесты никогда не трогают рабочую БД: интеграционные требуют явный адрес базы с суффиксом `_test`, Qdrant - коллекции `test_*`. Unit-графы используют память; интеграционные review - PostgresSaver в отдельной тестовой БД. Итог удалённых запусков смотри в GitHub Actions: локальная проверка его не заменяет.

11 Интерфейс оператора

Streamlit-панель поверх того же HTTP API: обращения, очередь проверки и поиск в браузере.



У процесса UI есть только API_URL: ни DATABASE_URL, ни ключа модели.
Все решения, SQL и вызовы модели остаются на сервере FastAPI.

Раздел	Что делает оператор
Обзор	Агрегаты всей БД: обращения, открытые и срочные, время анализа, доля одобрений
Обращения	Создание с выбором клиента и продукта по названию; фильтры, карточка, анализ, история и смена статуса
Очередь проверки	Предложения pending / approved / rejected; правка текста, одобрение или отказ с причиной
База знаний	Поиск фрагментов по запросу и продукту, путь к статье
Справочники	Клиенты, продукты, лицензии (ключи скрыты) и сотрудники

Создание обращения: сначала выбери клиента (имя и email) и продукт (название и код). В каждом списке по 20 записей; поиск действует на текущей странице, остальные доступны кнопками Назад/Далее. Затем заполни тему, описание и приоритет и нажми Создать обращение. До выбора обеих записей кнопка недоступна. Смена списков обновляет страницу и может сбросить ещё не отправленный текст; сначала выбери обе записи. Пустой список пополняется в разделе Справочники.

Запуск

```
docker compose up --build --detach --wait --wait-timeout 180 ui
docker compose exec -T api python -m app.knowledge.ingest
# интерфейс: http://127.0.0.1:8502
```

Изменения - только по явной форме. Перерисовка страницы не повторяет анализ и решение; вызов реальной модели требует отдельного подтверждения; POST не повторяется автоматически. Вход - токеном сотрудника в боковой панели; форма решения - только reviewer и admin.

12 Оценки и демонстрация

Числа вместо впечатлений и повторяемый показ без ключа модели.

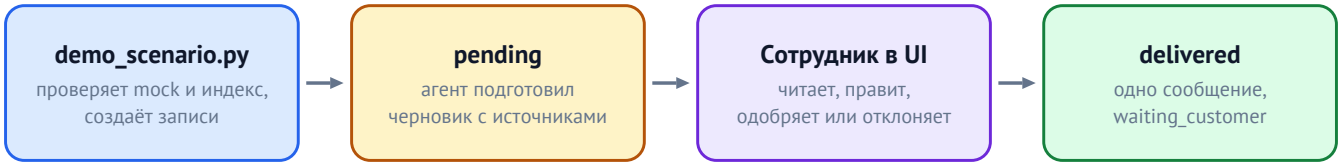
0.98	1.00	1.00	12/12
Recall@5: нужные статьи в первых пяти (порог 0.75)	MRR@5: первая верная статья наверху (порог 0.65)	молчание на вопросы без ответа (порог 0.80)	сценариев безопасности агента (нужны все)

Набор: 32 размеченных вопроса к семи статьям, из них шесть без ответа в базе. Qdrant строится в памяти тем же кодом, что и в API; сеть, ключи и PostgreSQL не нужны. Нарушение любого порога делает CI красным.

Что пытается сделать модель	Что делает сервер
Сослаться на статью, которую не искала	Запуск отклонён
По injection вызвать send_email или save_draft	unknown_tool: таких инструментов нет
Прочитать чужое обращение или чужой продукт	out_of_scope / invalid_arguments
Превысить лимит шагов или вызовов	Остановка до выполнения лишнего

Демонстрация за 5-7 минут

```
uv run --locked python scripts/demo_scenario.py \
  --url http://127.0.0.1:8001
```



Скрипт работает от имени сотрудника токена API_TOKEN, проверяет mock и индекс, создаёт или переиспользует вымышленные записи и оставляет одно предложение pending. Решение принимает человек в интерфейсе; повтор скрипта ничего не дублирует. Порядок показа - docs/DEMO.md.

> Оценки проверяют учебный mock-поиск и серверные гарантии. Качество, стоимость и задержка реальной модели не измерялись: в отчёте они явно помечены как not measured.

13 Дорожная карта

Десять этапов учебного проекта: все готовы.

01	**FastAPI, /health, первые тесты** основа API, uv, Ruff, Pytest	готово
02	**PostgreSQL, модели, миграции** 9 таблиц, Alembic, /ready, Docker Compose	готово
03	**REST API ресурсов** клиенты, продукты, лицензии, обращения	готово
04	**LLM-черновик, mock и OpenAI** строгий JSON, безопасные ошибки	готово
05	**Агент с инструментами** цикл tool calling, лимиты, сохранённый запуск	готово
06	**База знаний, RAG, Qdrant** индексация статей, поиск, ссылки агента	готово
07	**LangGraph и решение человека** одобрение, доставка, checkpoint в БД	готово
08	**Интерфейс оператора** Streamlit поверх API, очередь проверки, отдельный образ	готово
09	**Оценки качества и безопасность** 32 вопроса поиска, 12 сценариев агента, пороги в CI	готово
10	**Упаковка и демонстрация** Compose с UI, повторяемый демо-сценарий, DEMO.md	готово

Каждый этап - отдельная пошаговая инструкция на русском: `docs/STAGE_01.md` … `STAGE_10.md`, сценарий показа - `docs/DEMO.md`. В журнале `docs/DEVELOPMENT_LOG.md` записано, что именно проверено и чем.

14 Словарь и куда читать дальше

Термины, которые встречаются в проекте.

Термин	Простыми словами
API	Набор адресов (маршрутов), через которые программы общаются с сервером.
FastAPI	Фреймворк Python для HTTP API; сам строит документацию /docs.
Миграция	Версия изменения схемы БД; Alembic применяет их по порядку.
Docker Compose	Запуск нескольких связанных контейнеров одной командой.
LLM / mock	Языковая модель / локальная заглушка без сети и платы.
Агент	Программа, которая просит инструменты, получает факты и готовит итог.
Tool calling	Протокол: модель просит вызвать функцию, сервер её выполняет.
RAG	Ответ с опорой на найденные документы и ссылками на них.
Эмбеддинг	Список чисел, описывающий текст; близкие тексты - близкие векторы.
Qdrant	Векторная БД: быстро находит похожие векторы с фильтрами.
LangGraph	Библиотека для процессов-графов с состоянием и остановками.
Checkpoint	Сохранённое состояние графа после шага; здесь - в PostgreSQL.
Interrupt / resume	Остановка графа до решения и продолжение с этим решением.
Human in the loop	Шаг, где решение принимает человек, а не модель.
Smoke-тест	Быстрая проверка, что запущенная система отвечает как надо.
CI/CD, GHCR	Автопроверки на GitHub и публикация образов API/UI в реестр.
Streamlit	Библиотека Python для веб-интерфейса из обычного скрипта.
Recall@5 / MRR	Доля нужных статей в первых пяти / насколько высоко первая из них.

Куда читать дальше

Файл	Что там
`README.md`	Краткое описание, дорожная карта, оглавление
`docs/instructions/`	Быстрый запуск, Windows и PowerShell, работа с API, тесты, CI, структура проекта
`docs/STAGE_01-10.md`	Пошаговые учебные инструкции по этапам; DEMO.md - показ
`docs/APPROACH.md`	Архитектура и решения (англ.)
`docs/CI_CD.md`	Подробно о GitHub Actions и GHCR
`docs/DEVELOPMENT_LOG.md`	Что сделано и как проверено на каждом этапе

15 Итоги полной проверки

Результаты относятся к этой версии исходников; удалённый CI проверяется отдельно.

Дата аудита: **2026-10-19**. Исходный коммит: `4962feb`. Проверяются приложение, миграции, поиск, процесс решения, образы API/UI и документация.

Группа	Результат
Полный Pytest	1306 passed; 0 skipped
Unit / интеграционные	1143 / 163
Smoke CLI (входит в unit)	112
Контракт HTTP	28 URL-путей, 35 операций

Проверка	Фактическое свидетельство
Код и комментарии	Ruff без замечаний; 140 файлов Python, 1799 функций/классов с docstrings.
Инструкции	Текущая проверка: 28 Markdown, 390 ссылок, 196 Bash и JSON PASS. 33 PowerShell-блока локально не разобраны; parser есть в CI.
Покрытие	92.97% строк и ветвей вместе при пороге 85%; полный прогон 1306 тестов, CLI subprocess учтены.
CI и платформы	1a495e9: 8 зелёных заданий со слов пользователя. Три workflow: actionlint PASS; CI нового backup-коммита 4962feb ещё не подтверждён.
Токены и роли	SHA-256 токенов; operator/reviewer/admin; 401/403/429; автор решения из токена, конкурентные PG-проверки.
Зависимости	Ранее: Linux audit: 88 пакетов API/UI, 0 известных уязвимостей и пропусков. 99 пакетов lock старше 14 дней.
Оценки	Recall@5 0.9808; MRR@5/no-hit 1.00; scope 0; 12/12 сценариев агента; реальная модель не вызывалась.
Образы и GHCR	Ранее: 4 образа amd64/arm64, Trivy и SBOM PASS; очистка GHCR dry-run, 230 тестов; публичная подпись выключена.
Контейнерный CI	Ранее: Миграции, токены, review/resume, тома, UI AppTest, demo approve/reject и повтор, журнал без секретов: PASS.
Локальный запуск	Ранее: Настоящие Uvicorn/Streamlit на macOS: PASS. Нативные Windows/Linux проверяет матрица GitHub.
Резервные копии	61 unit PASS повторно. Локальный restore ранее прошёл; найдены ограничения проверки изменений и отказа между заменой двух хранилищ.
Персональные данные	Обезличивание и срок хранения: 44 теста; поиск по всем таблицам и checkpoint чист; шаг container локально PASS.

> Пользователь подтвердил 8 зелёных заданий для 1a495e9. Во время проверки backup отправлен в main: 4962feb; его CI пока не подтверждён. Повторно прошёл 61 unit-тест. Есть замечания к согласованности и восстановлению при сбое. Подпись выключена.

Как читать эту страницу

Тесты проверяют сценарии, а не качество настоящей модели. Публикацию подтверждает успешный Actions итогового SHA; локального прогона для этого недостаточно.

16 CI: матрица проверок

Каждый push в main проходит последовательные барьеры перед публикацией API и UI для amd64 и arm64.

Событие	Проверки / образ	GHCR
Локальный git commit	Не запускаются на GitHub	Нет
Push в main	Все обязательные задания	После успеха
Push vX.Y.Z из main	Все шесть заданий; проверка истории	Версия API/UI
PR с целью main	delivery → checks/security/OC → container	Нет
Run workflow вручную	delivery → checks/security/OC → container	Нет

Барьер	Что проверяется	Зачем
delivery	Строгий vX.Y.Z; commit достижим из origin/main	Нельзя выпустить стороннюю ветку
Зависимости	uv 0.12.23; lock; возраст ⩾ 14 дн.; pip-audit	Нет слишком свежих и известных уязвимых выпусков
checks: код и документы	Ruff, формат, документы, actionlint всех workflow	Ошибки кода, комментарии, ссылки
PostgreSQL + Qdrant	Миграции, alembic check, Pytest; coverage ⩾ 85%	Схема, поиск, строки и ветви кода
Оценки	32 вопроса поиска, 12 сценариев агента	Пороги качества и безопасности
Контейнер	Образы API и UI: readiness, UID, состав	Готовые образы без root и лишнего
Полный сценарий	Ingest; агент; review; повтор решения	Путь от обращения до сообщения
Пересоздание, копия	Тома, pending; backup → restore	Данные в томах и в копии
UI и демо	Health UI; демо с обеими ветвями; повтор	Показ воспроизводится без ручных шагов
Сканирование	Trivy 0.75.0 по digest; HIGH/CRITICAL с исправлением	Известные уязвимости ОС и Python в образах
Журнал	JSON-строки запросов; нет ключей smoke и демо	Секреты не попадают в логи
Переносимость	Linux, macOS, Windows: uv.lock, тесты, запуск API/UI	Проект работает на любой ОС разработчика
arm64	Сборка, запуск и Trivy под QEMU	Родной образ на Apple Silicon и ARM
Доставка	4 tested образа и SBOM; cosign по выбору	Проверенные сборки под общим тегом

> Ошибка обязательного задания останавливает цепочку. Следующие задания могут стать Skipped: сначала ищи первый неуспешный шаг. На PR пропуск publish ожидаем. Полный состав шагов определяет .github/workflows/ci.yml.

Проверенные образы на весь путь

container собирает и проверяет API и UI для amd64 и arm64. В publish передаются tested-images.tar и JSON с SHA коммита и четырьмя image ID; после загрузки проверяются ID и платформы. Теги -amd64 и -arm64 получают те же образы, общий тег — index из их digest. Это защищает от ситуации, когда тестируется одна сборка, а доставляется другая.

17 Защита и доставка

Технические ограничения проекта, права GitHub и воспроизводимые версии API и UI для двух архитектур.

Область	Как устроено
Права GitHub	CI: contents: read; packages: write и id-token: write только в publish
Внешние Actions	Версии закреплены полным SHA; actionlint 1.7.12 игнорирует только новое queue: max
Секреты	GITHUB_TOKEN выдаётся заданию; .env и ключи не входят в образ
Режим CI	LLM и embeddings = mock; OpenAI credentials пустые
Процесс API	Постоянный пользователь UID 10001; dev-инструментов в runtime нет
Агент	Строгие аргументы, серверная область данных, READ ONLY инструменты
Тесты	Отдельная *_test БД, временные test_* коллекции Qdrant
Образы	Сторонние образы по digest; Trivy без trivy-action (CVE-2026-33634)
Журнал API	JSON с X-Request-ID; без query string, SQL, тел запросов и ключей
Персональные данные	admin обезличивает клиента по email; срок хранения закрытых обращений — app.privacy retention
Публикация API/UI	main: sha-<полный SHA> для amd64 и arm64; latest только для вершины
Версия vX.Y.Z	Push тега из истории main; конфликт образа запрещён; latest не меняется
Подпись и SBOM	SBOM Trivy всегда проверяется. Публичная подпись выключена; включение: GHCR_PUBLIC_SIGNING=true (Rekor)
Очистка GHCR	SHA-версии старше 30 дней: план по воскресеньям, удаление по явному разрешению; latest и vX.Y.Z не трогаются

Как получить ровно проверенную версию

Actions → CI and GHCR → нужный коммит → Publish tested image to GHCR. В Summary скопируй полный тег sha-… или digest index: Docker сам возьмёт arm64 или amd64 под свой компьютер. latest меняется со следующими версиями; digest обозначает содержимое конкретного образа.

```
read -r -p "Полный SHA из Summary: " IMAGE_SHA
export APP_IMAGE="ghcr.io/merkertg/ai-support-agent:sha-$IMAGE_SHA"
export UI_IMAGE="ghcr.io/merkertg/ai-support-agent-ui:sha-$IMAGE_SHA"
docker pull "$APP_IMAGE"
docker pull "$UI_IMAGE"
docker compose up --detach --no-build --wait ui
```

> Для закрытого GHCR-пакета требуется вход аккаунтом с доступом. Локальный токен read:packages передавай через скрытый ввод/--password-stdin. Не добавляй его в .env.example, код или историю команд.

Граница реализованной защиты

Аудит зависимостей ищет известные уязвимости на дату проверки. Оценки не измеряют качество реальной модели. API закрыт токенами сотрудников (хранится только SHA-256) с ролями operator/reviewer/admin и лимитом изменений; входа через SSO нет. CD заканчивается в GHCR: внешняя площадка развёртывания пока не выбрана.

18 Полный локальный прогон

Команды из корня проекта. Для сброса схемы используются отдельные тестовые сервисы.

1. Подготовить окружение и одноразовые зависимости

```
cp -n .env.example .env
uv sync --locked
docker compose --profile test up --detach --wait \
  db-test qdrant-test
```

2. Проверить код и документацию

```
uv run --locked ruff check .
uv run --locked ruff format --check .
uv run --locked python scripts/check_dependency_age.py
uv run --locked python scripts/check_project.py
uv run --locked python -m evaluations.run
```

3. Выполнить весь Pytest без пропусков

```
export TEST_DATABASE_URL='postgresql+psycopg://support:'\
'support_ci@127.0.0.1:5434/ai_support_test'
export TEST_QDRANT_URL=http://127.0.0.1:6336
CI=true uv run --locked pytest --cov \
  --cov-report=term-missing:skip-covered \
  --cov-report=xml --cov-report=json --cov-report=html
unset TEST_DATABASE_URL TEST_QDRANT_URL
```

4. Проверить запуск API и UI на этом компьютере

```
uv run --locked python scripts/check_local_start.py
```

5. Проверить собранный стенд через HTTP

```
docker compose up --build --detach --wait --wait-timeout 180 ui
docker compose exec -T api python -m app.knowledge.ingest
docker compose exec -T api python -m alembic check
export API_TOKEN="$(docker compose exec -T api python -m app.tokens \
  issue --email admin@example.com --name Admin --role admin)"
uv run --locked python scripts/smoke_test.py \
  --base-url http://127.0.0.1:8001 \
  --timeout 60 --check-review
```

Ожидается код завершения 0 у всех команд, ноль пропусков в полном Pytest, миграции без различий и успешные шаги smoke. --check-review нужен токен admin; он проверяет 401/403 и создаёт учебные записи: выполняй на учебном стенде. Без TEST URLs локальные интеграционные тесты пропускаются; CI=true превращает отсутствие адресов в ошибку.

19 Практика оператора

Полный путь через Swagger: можно повторить без программирования и ключа модели.

Открой http://127.0.0.1:8001/docs, нажми Authorize и вставь токен администратора (python -m app.tokens issue). В нужной операции нажми Try it out, заполни JSON и Execute. ID бери из ответов: они различаются на разных стендах.

Шаг и операция	Что передать / что увидеть
1. GET /api/llm/status	provider=mock, configured=true; затем GET /api/knowledge/status: index=ready
2. POST /api/customers	name: Учебный клиент; email: новый адрес @example.com. Сохранить customer.id
3. Продукт и лицензия	GET /api/products: взять techflow-server. Если его нет, POST /api/products: name=TechFlow Server, code=techflow-server. Затем POST /api/licenses: customer_id, product_id, новый license_key
4. POST /api/users	name, новый email и role=reviewer; затем POST /api/users/{id}/tokens - токен рецензента (виден один раз)
5. POST /api/tickets	customer_id, product_id, subject и description проблемы. Начальный статус open
6. POST .../{id}/analyze	{"license_key":"ключ шага 3"}. Запуск completed, предложение pending, sources из найденных статей
7. GET .../{run_id}/workflow	state=awaiting_review, next=[human_review]. Это ожидание сотрудника
8. POST /api/suggestions/{id}/review	Authorize токеном рецензента; decision=approve, можно final_content. Автор решения - владелец токена
9. Проверить результат	suggestion approved, message operator, ticket_status waiting_customer, workflow delivered
10. Повторить решение	HTTP 409: предложение уже рассмотрено, второго сообщения нет

Отдельно пройти отклонение

Создай второе обращение и запусти анализ. Для pending предложения передай decision=reject и обязательный comment с причиной (токен reviewer или admin); final_content не передавай. Ожидаются rejected, message=null, обращение остаётся open. Пошаговые curl-блоки с сохранением ID находятся в docs/STAGE_07.md, разделы 9-10.

> Перед одобрением прочитай источники и исправь ответ. Mock показывает путь данных, а не качество технической рекомендации. «Доставка» здесь означает сообщение в PostgreSQL, не письмо и не ответ во внешней системе.

20 Перезапуск, данные и копии

Тома при down/up, резервная копия с восстановлением и ожидающее решение.

Состояние	Где хранится	После обычного down / up
Предметные записи и run	Том postgres_data	Сохраняются
Решение и сообщение	PostgreSQL	Сохраняются
Ожидание human_review	checkpoint_* в PostgreSQL	Можно продолжить
Векторы статей	Том qdrant_data	Сохраняются
Учебные db-test/qdrant-test	tmpfs / временные данные	Одноразовые

Сравнить предметные данные до и после

```
docker compose exec -T api python -m app.db.demo seed > /tmp/ai-support-before.json
docker compose down
docker compose up --detach --no-build --wait ui
docker compose exec -T api python -m app.db.demo show > /tmp/ai-support-after.json
cmp /tmp/ai-support-before.json /tmp/ai-support-after.json
```

cmp с кодом 0 без вывода подтверждает совпадение снимков. После up не выполняй повторный seed до сравнения: он мог бы заново создать потерянные записи.

Обновить стенд до новой версии

```
docker compose up --build --detach --wait --wait-timeout 180 ui
```

Без down: Compose пересобирает образы, применяет миграции и пересоздаёт только изменившиеся контейнеры; тома остаются. Так обновлён development-стенд: снимок 14 таблиц до и после совпал.

Резервная копия и восстановление

```
uv run --locked python scripts/backup.py create --output-dir "$HOME/ai-support-backups"
docker compose up --detach --wait db qdrant   # чистые тома
uv run --locked python scripts/backup.py restore "$backup"
```

pg_dump в контейнере db, snapshot Qdrant и manifest.json (Alembic, SHA256, строки). restore сверяет копию и версию Alembic, требует остановленный api и пустую цель (иначе --force) и заменяет рабочую БД последней. Копия секретна: храни вне Git и репозитория (docs/instructions/backup.md).

Проверить ожидающий процесс

Создай анализ и сохрани run_id, оставив предложение pending. Пересоздай контейнеры обычным down/up. GET /api/agent-runs/{id}/workflow должен снова показать awaiting_review. Прими решение через review: граф продолжится из checkpoint. CI повторяет этот сценарий автоматически и дополнительно сравнивает индекс поиска. При сбое saver чтение workflow восстанавливает checkpoint из AgentRun/AgentSuggestion под advisory lock. Анализ и доставка при восстановлении не повторяются.

> Обычный down сохраняет тома; --volumes удаляет данные и применяется CI только к своему проекту, где копия восстанавливается в чистые тома. Брошенные running завершаются автоматически: порог 180 с, таймер 30 с (раздел 22).

21 Диагностика ошибок

Начинай с первого неуспешного шага; повторная публикация не исправляет ошибку тестов.

Симптом	Что проверить	Следующее действие
Нет docker.sock, dependency failed	Docker Desktop и docker version	Запустить Docker и повторить up; тома целы
UI: нет соединения с API	compose ps; API_URL=http://api:8000	Дождаться healthy api, обновить страницу
UI: код запроса	docker compose logs api, поиск кода	Класс ошибки, SQLSTATE, ответ провайдера
Порт занят	compose ps; API_PORT, POSTGRES_PORT	Выбрать свободный порт и согласовать URL
/health 200, /ready 503	Логи db/migrate; Alembic current	Исправить БД или применить миграцию
Индекс missing	GET /api/knowledge/status	Выполнить явный ingest
Индекс incompatible	Модель и размерность embeddings	Согласовать настройки, переиндексировать
HTTP 422	JSON, лишние поля, ID, поля решения	Сверить схему Swagger; reject требует comment
HTTP 401 / 403 / 429	Bearer-токен, срок и отзыв, роль, лимит в минуту	Новый токен (app.tokens issue), роль или пауза
HTTP 409	Предложение, статус обращения, запуски	Принять решение, отклонить или сменить статус
HTTP 502 / 504	run_id, safe error, лимиты	Изучить failed run, исправить причину
Windows: кракозябры, cp1252	Кодировка консоли PowerShell	[Console]::OutputEncoding = UTF8; PowerShell 7
Windows: $'\r' в bash	CRLF в старой копии репозитория	git rm --cached -r . и git reset --hard
Тесты skipped локально	TEST_DATABASE_URL, TEST_QDRANT_URL	Поднять test-сервисы, повторить полностью
GitHub: container Skipped	Результат предыдущего задания	Исправить первый сбой checks/security
GHCR denied	Права пакета, владелец, GITHUB_TOKEN	Проверить Packages/Actions permissions

Команды для сбора понятной диагностики

```
docker compose ps --all
docker compose logs --no-color --tail 100 \
  api ui migrate db qdrant
docker compose logs --no-color api | grep '"level": "ERROR"'
docker compose exec -T api python -m alembic current
```

В GitHub открой CI and GHCR → нужный коммит → первый красный шаг. JUnit лежит в pytest-report; контейнерные логи показывают зависимости. После исправления повтори весь workflow, если архив проверенного образа уже удалён. Новый Run workflow выполняет проверки без publish.

22 Покрытие и восстановление

Как повторить порог качества и что произойдёт после остановки worker.

1. Выполнить полный прогон с покрытием

Сначала подними db-test/qdrant-test и задай TEST URLs из раздела 18. Один полный запуск проверяет приложение, UI, оценки и CLI:

```
CI=true uv run --locked pytest --cov \
  --cov-report=term-missing:skip-covered \
  --cov-report=xml --cov-report=json --cov-report=html
```

Порог **85%** задаётся в pyproject.toml: это общий показатель строк и ветвей, а не отдельный порог каждого файла. patch=subprocess объединяет дочерние Python-процессы smoke с Pytest. Макет PDF исключён из числового покрытия: он проверяется рендером. Недобор даёт код 1 и блокирует container/publish даже при зелёных assertions.

Отчёт	Где смотреть
coverage.xml / coverage.json	reports/: машинные результаты
coverage-html/index.html	reports/: строки и ветви по файлам
Артефакт coverage-report	GitHub Actions: XML, JSON, HTML; 7 дней

2. Проверить восстановление брошенного запуска

Сервер сохраняет running до вызова агента. После сбоя процесса монитор каждые **30 секунд** переводит только running возрастом **не менее 180 секунд** в failed. Время берётся из PostgreSQL: 120 секунд максимального лимита плюс запас 60. Перед новым анализом того же обращения действует та же проверка.

```
docker compose logs --since 10m api
read -r -p "ID проверяемого запуска: " RUN_ID
curl --fail-with-body \
  -H "Authorization: Bearer $API_TOKEN" \
  "http://127.0.0.1:8001/api/agent-runs/$RUN_ID"
```

Ищи событие agent_run_recovered и статус failed с finished_at. Recovery не создаёт предложение и не отправляет ответ; сохранённый прогресс остаётся. Поздний worker получает 409 и не оживляет failed. Успевший completed и его pending сохраняются. Ошибка БД откатывает проход; таймер повторит попытку. Проверки гонок выполняются только в тестовой БД, рабочий процесс для демонстрации не останавливай.

> RUN_RECOVERY_ENABLED=false отключает таймер, но сохраняет проверку перед анализом. SQL ограничен statement_timeout=3s и lock_timeout=1s; занятая БД может задержать проход. Инструкция: docs/RUN_RECOVERY.md.

23 Обновления и версии релизов

Как получить проверяемую PR зависимостей и опубликовать выбранную версию.

1. Еженедельная PR зависимостей

Update Python dependencies запускается по понедельникам в **06:17 UTC / 11:17 Ташкент** или вручную только из main. prepare без write-токена сдвигает exclude-newer до полуночи UTC за 14 суток и выполняет uv lock --upgrade --no-build. Age check повторно проверяет upload-time всех пакетов.

Шаг	Ожидаемый результат
prepare → publish	Только pyproject.toml и uv.lock; код из main
Bot-ветка	automation/python-dependencies: одна PR, без автослияния
Отдельный dispatch CI	Обычные проверки этой ветки; GHCR не публикуется
После review и зелёного CI	Человек сливает PR; main запускает полный CI/CD

uv 0.12.23 опубликован 03.10.2026; совместимость актуального lock проверена. Оба builder используют его закреплённый digest. Точные ограничения вроде streamlit==1.65.0 сохраняются. Docker digest, Actions SHA и диапазоны пакетов пересматриваются отдельно. HTTP 403 при создании PR требует разрешения в настройках Actions; PAT для обхода скрипт не подставляет. Политика и разбор ошибок: docs/DEPENDENCY_UPDATES.md.

2. Выбрать стабильную версию vX.Y.Z

Версию выбирает человек после просмотра успешного CI нужного SHA. Тег должен указывать на commit из истории origin/main; development- и PR-ветки не выпускаются. Разрешён строгий vMAJOR.MINOR.PATCH, без суффиксов и ведущих нулей. Команды ниже выполняют явный релиз:

```
set -e
git fetch origin main --tags
read -r -p "Проверенный полный SHA из main: " RELEASE_SHA
read -r -p "Выбранный тег vX.Y.Z: " RELEASE_VERSION
git merge-base --is-ancestor "$RELEASE_SHA" origin/main
git tag -a "$RELEASE_VERSION" "$RELEASE_SHA" -m "$RELEASE_VERSION"
git push origin "refs/tags/$RELEASE_VERSION"
```

Push тега запускает шесть jobs: delivery → checks/security/portability → container → publish. API и UI для amd64 и arm64 получают vX.Y.Z-amd64, vX.Y.Z-arm64 и общий vX.Y.Z; повторной сборки в publish нет. Существующий version-тег с другим image ID останавливает доставку. Повтор идентичного образа разрешён. Релиз не двигает latest; main публикует sha-<полный SHA> и latest только для своей текущей вершины. Публичная подпись выключена по выбору пользователя. GHCR_PUBLIC_SIGNING=true включает cosign keyless и SBOM attestations; metadata появятся в Rekor. Проверка: docs/RELEASES.md, раздел 5.

3. Очистка старых SHA-образов

Clean up old GHCR SHA images по воскресеньям строит план: SHA-версии main старше 30 дней вместе с их подписями. latest, vX.Y.Z и всё, на что они ссылаются, остаются. По умолчанию dry-run; удаление — отметка delete при ручном запуске или GHCR_CLEANUP_DELETE=true.

> CI настраивает доставку, но локальная проверка не доказывает результат GitHub. Подтверди шесть jobs итогового коммита, оба пакета GHCR и статус выключенной подписи в Actions Summary. Тег и GitHub Release автоматически не создаются.

24 Что делать дальше

Десять этапов готовы; дальше - реальная модель, доступ и эксплуатация.

Что изменено при этом аудите

• Доступ: токены сотрудников, роли operator/reviewer/admin и лимит изменений; автор решения — из токена, FOR SHARE против понижения роли.
• Образы: amd64/arm64 и SBOM; очистка GHCR проверяет связи и версии; публичная подпись выключена по выбору пользователя.
• Исправлен дедлайн smoke на Windows; форма обращения выбирает клиента и продукт по имени.
• Резервные копии: backup.py create/verify/restore с манифестом и проверкой восстановления в чистые тома в CI.
• Персональные данные: администратор обезличивает клиента по email (UI, API, CLI); срок хранения закрытых обращений; поиск маркера по всем таблицам в CI.

Следующая работа	Критерий готовности
Реальный OpenAI	Пользователь задаёт ключ и доступную модель локально; тот же набор оценок с отчётом о стоимости
Вход через SSO	OIDC поверх готовых ролей и токенов; общий лимит изменений в шлюзе или Redis; TLS на внешнем адресе
Настоящая доставка	Email или helpdesk; учёт повторов, журнал попыток, тест отказа внешнего сервиса
Подтвердить удалённый CI	Шесть успешных jobs итогового SHA, оба пакета GHCR, SBOM и первый dry-run очистки
Внешний сервер	Выбрана площадка и секреты; расписание backup.py и шифрованное хранилище копий; проверка после deploy

Остающиеся ограничения

• Завершить backup: согласованность копии и возврат при сбое между Qdrant/PostgreSQL; затем проверить отдельный CI нового SHA.
• SSO, общий лимит нескольких worker и внешний TLS остаются отдельным расширением; локальный вход администратора уже подготовлен.
• Публичная подпись выключена; GHCR_PUBLIC_SIGNING=true включает её и раскрытие metadata в Rekor.
• Mock остаётся по выбору пользователя. Реальная модель, внешняя доставка и серверный deploy не проверялись и не настроены.
• Расписание копий и шифрованное внешнее хранилище не настроены; шаг восстановления в CI ждёт первого удалённого запуска.
• Обезличивание не меняет старые резервные копии и журналы Docker: после восстановления копии повторить erase; срок хранения выбирает владелец данных.

> OpenAI-адаптеры уже есть, но реальный запрос и качество ответов не проверены. По текущему выбору пользователя сохраняется mock: ключ не нужен и платных вызовов нет. Подключение настоящей модели меняет стоимость и передачу данных; оно выполняется отдельным явным действием.

Документация и проверяемая история

Репозиторий проекта · GitHub Actions · Документация

Исходник этого PDF: scripts/build_guide.py. Проверенные числа и результаты: docs/guide/verification.json. Инструкция пересборки: docs/guide/README.md. Не меняй числа вручную в макете: обновляй свидетельства после полного прогона.